

Технический отчёт по проекту

Тема: Исследование влияния Retrieval-Augmented Generation на качество ответов и уровень галлюцинаций в задаче Question Answering

Выполнил: студент группы МПИ-25-1-2

Прохоров Д.Д.

Москва, 2026 г

Содержание

1. Постановка задачи.....	3
2. Данные и предобработка	3
2.1. Основной датасет.....	3
2.2. Дополнительные данные.....	4
2.3. Предобработка	4
3. Метрики оценки QA.....	4
4. Модели и подходы	5
4.1. TF-IDF sentence baseline	5
4.2. LLM без RAG	6
4.3. LLM + RAG с TF-IDF retrieval.....	6
4.4. LLM + RAG с E5 embedding retrieval.....	6
5. Протокол экспериментов.....	7
6. Основные результаты	7
7. Расширенные эксперименты.....	10
7.1. Популярность информации	10
7.2. Влияние русского и английского языка	10
7.3. Размер модели	10
8. Анализ ошибок	11
9. Ограничения подходов	12
10. Итоговые выводы	12
11. Список использованных источников	13

1. Постановка задачи

В проекте рассматривается задача Question Answering: система получает вопрос и должна выдать короткий ответ, опираясь на текстовый контекст. Основная исследовательская гипотеза состоит в том, что LLM без внешнего контекста склонна отвечать из внутренних знаний и чаще допускает галлюцинации, а LLM + RAG должна работать устойчивее, потому что перед генерацией ответа получает найденный релевантный фрагмент текста.

Цель работы - построить и сравнить несколько подходов к QA, оценить их по разным метрикам и отдельно исследовать влияние retrieval на уровень потенциальных галлюцинаций.

В работе сравнивались четыре основных варианта:

- TF-IDF sentence baseline: лексический поиск релевантного фрагмента и возврат наиболее похожего предложения.
- LLM без RAG: генеративная модель отвечает на вопрос без исходного контекста.
- LLM + RAG с TF-IDF retrieval: сначала ищется релевантный фрагмент, затем LLM отвечает по найденному контексту.
- LLM + RAG с E5 embedding retrieval: вместо лексического поиска используется семантический поиск по эмбедингам.

2. Данные и предобработка

2.1. Основной датасет

Основной датасет проекта - SberQuAD, русскоязычный набор данных для reading comprehension, extractive QA. Каждая запись содержит текстовый контекст, вопрос и правильный ответ. В экспериментах использовался split validation.

Таблица 1 - Характеристики основной подвыборки SberQuAD

Параметр	Значение
Источник	Hugging Face: kuznetsoffandrey/sberquad
Использованный split	validation
Размер split validation	5036 записей
Использовано в проекте	1500 примеров
Уникальные контексты	1387
Средняя длина контекста	101.27 слова
Медианная длина контекста	92 слова
Средняя длина вопроса	8.72 слова

Параметр	Значение
Средняя длина ответа	3.72 слова

2.2. Дополнительные данные

Для расширенных экспериментов были добавлены дополнительные наборы:

- SQuAD validation - небольшой английский QA-набор для сравнения русского и английского языка. Всего использовано 20 примеров.
- Ручной мини-набор из 8 фактов для эксперимента по популярности информации: 4 popular-факта и 4 context-specific-факта.
- Подвыборка из 10 примеров SberQuAD для сравнения моделей Qwen2.5-0.5B-Instruct и Qwen2.5-1.5B-Instruct.

2.3. Предобработка

Предобработка была минимальной, чтобы не исказить задачу QA. Были выполнены следующие шаги:

- Извлечение первого корректного ответа из поля answers. В ноутбуке использована устойчивая функция, которая обрабатывает dict, list, numpy-array и строковые форматы.
- Фильтрация некорректных записей: после обработки осталось 1500 валидных примеров.
- Нормализация текста для метрик: приведение к нижнему регистру, удаление пунктуации, нормализация пробелов.
- Чанкинг контекстов для RAG: использовались chunk_size 200, 300 и 500 слов, overlap 50 слов.
- Отдельная токенизация для метрик EM/F1: ответ и эталон сравнивались по нормализованным токенам.

3. Метрики оценки QA

Для QA нельзя ограничиться только ассурасу, потому что модель может дать ответ, который не совпадает с эталоном дословно, но частично или смыслово близок к нему. Поэтому в работе использовалось несколько метрик, каждая из которых показывает отдельную сторону качества.

Таблица 2 - Метрики оценки QA

Метрика	Что измеряет	Как интерпретируется
Exact Match (EM)	Строгое совпадение нормализованного ответа с эталоном.	Полезен как строгая метрика, но слишком жёсткий для генеративных ответов.
Token F1	F1 между токенами предсказания и эталонного ответа.	Основная метрика: учитывает частичное совпадение и лучше подходит для LLM-ответов.
Recall@k / retrieved_contains_answer_rate	Доля случаев, когда правильный ответ содержится в найденных top-k чанках.	Показывает качество retrieval-этапа; если ответ не найден, LLM почти не сможет ответить правильно.
Hallucination-like rate	Эвристическая доля ответов, которые почти не совпадают с эталоном и не являются отказом.	Приблизённо оценивает потенциальные галлюцинации, но не заменяет ручную проверку фактов.
Refusal rate	Доля ответов, где модель отказывается отвечать или пишет, что информации нет.	Позволяет отличить отказ от галлюцинации: модель может не выдумывать, но и не решать задачу.

Основной метрикой для сравнения выбран Token F1, потому что он лучше отражает частичное совпадение ответа с эталоном. EM используется как строгая дополнительная метрика. Для RAG отдельно анализируется retrieved_contains_answer_rate, потому что это позволяет отделить ошибку поиска от ошибки генерации.

4. Модели и подходы

4.1. TF-IDF sentence baseline

Этот baseline подходит для QA, как простая интерпретируемая точка отсчёта. Он не использует LLM и показывает, насколько далеко можно продвинуться только за счёт лексического поиска.

Pipeline подхода:

1. Разбить контексты на чанки.
2. Построить TF-IDF-векторы для чанков.
3. Для вопроса найти top-k наиболее похожих чанков по cosine similarity.
4. Выбрать предложение с максимальным совпадением с вопросом и вернуть его как ответ.

Ограничение: baseline зависит от совпадения слов и часто возвращает слишком длинный фрагмент вместо короткого ответа.

4.2. LLM без RAG

Второй baseline использует instruction-модель Qwen/Qwen2.5-0.5B-Instruct. Он нужен, чтобы проверить, насколько хорошо LLM отвечает на вопросы без исходного контекста.

Pipeline подхода: вопрос передаётся в prompt, затем LLM генерирует короткий ответ. Были использованы plain и strict prompt.

Ограничение: модель не видит исходный контекст SberQuAD и вынуждена отвечать из внутренних знаний. Поэтому она часто угадывает, галлюцинирует или отказывается.

4.3. LLM + RAG с TF-IDF retrieval

Это основной подход проекта. Он объединяет поиск и генерацию: retrieval находит релевантный контекст, а LLM формулирует ответ на основе найденного фрагмента.

Pipeline подхода:

5. Чанки контекстов индексируются через TF-IDF.
6. Для вопроса выбираются top-k релевантных чанков.
7. В prompt передаются найденный контекст и вопрос.
8. LLM отвечает на вопрос, желательно только по переданному контексту.

Ограничение: RAG зависит от retrieval. Если top-k чанки не содержат правильный ответ или содержат слишком много шума, LLM может ошибиться.

4.4. LLM + RAG с E5 embedding retrieval

Дополнительный вариант RAG использует модель intfloat/multilingual-e5-small для семантического поиска. Такой retrieval может находить релевантные фрагменты даже при слабом лексическом совпадении.

Pipeline похож на TF-IDF RAG, но вместо TF-IDF-векторов используются dense embeddings вопроса и чанков. Сравнение проводится по cosine similarity.

Ограничение: embedding retrieval требует больше вычислений. Кроме того, высокий Recall@k не гарантирует высокий итоговый F1, потому что генерация ответа остаётся отдельным источником ошибок.

5. Протокол экспериментов

Проект построен как evaluation-only исследование. Модели не обучались с нуля и не дообучались, поэтому классический train/validation/test split в смысле обучения не применялся. Вместо этого использовался validation split SberQuAD как фиксированный набор для оценки разных QA-пайплайнов.

- Основной корпус: 1500 записей из SberQuAD validation.
- Retrieval/baseline эксперименты: 250 вопросов.
- LLM-эксперименты: 30 вопросов, так как генерация медленнее поиска.
- Языковой эксперимент: 20 русских и 20 английских примеров.
- Эксперимент по размеру модели: 10 примеров для Qwen2.5-0.5B и Qwen2.5-1.5B.
- Для воспроизводимости использовался seed = 42.
- Условия сравнения: одинаковые вопросы внутри соответствующего блока экспериментов и одинаковые метрики.

Варьируемые параметры:

- chunk_size: 200, 300, 500 слов;
- top_k: 1 и 3;
- retriever: TF-IDF и E5 embeddings;
- prompt_type: plain и strict;
- temperature: 0.0;
- язык: русский и английский;
- размер модели: Qwen2.5-0.5B-Instruct и Qwen2.5-1.5B-Instruct.

6. Основные результаты

Таблица 3 - Основные эксперименты

№	Подход	Настройки	n	EM	F1	Hall.	Retrieval
1	TF-IDF sentence baseline	chunk=200; top_k=1	250	0.0000	0.2120	0.5680	0.7440
2	TF-IDF sentence baseline	chunk=300; top_k=1	250	0.0000	0.2120	0.5680	0.7440
3	TF-IDF sentence baseline	chunk=300; top_k=3	250	0.0040	0.2346	0.5160	0.8800
4	TF-IDF sentence baseline	chunk=500; top_k=3	250	0.0040	0.2346	0.5160	0.8800

№	Подход	Настройки	n	EM	F1	Hall.	Retrieval
5	LLM no RAG	prompt=plain; temperature=0.0	30	0.0000	0.0621	0.9000	-
6	LLM no RAG	prompt=strict; temperature=0.0	30	0.0000	0.0564	0.8000	-
7	LLM + RAG	retriever=tfidf; chunk=300; top_k=1; prompt=strict	30	0.1333	0.3990	0.2667	0.7667
8	LLM + RAG	retriever=tfidf; chunk=300; top_k=3; prompt=strict	30	0.1333	0.4388	0.2667	0.8667
9	LLM + RAG	retriever=tfidf; chunk=500; top_k=3; prompt=strict	30	0.1333	0.4388	0.2667	0.8667
10	LLM + RAG	retriever=tfidf; chunk=300; top_k=3; prompt=plain	30	0.1667	0.4628	0.2667	0.8667
11	LLM + RAG	retriever=e5; chunk=300; top_k=3; prompt=strict	30	0.1667	0.4127	0.4000	0.9667




Рисунок 1 - Сравнение основных подходов по Token F1




Рисунок 2 - Сравнение основных подходов по hallucination-like rate

Лучший результат среди основных экспериментов показал LLM + RAG с TF-IDF retrieval, chunk_size=300, top_k=3, prompt_type=plain и temperature=0.0. Этот вариант получил EM = 0.1667, Token F1 = 0.4628 и hallucination-like rate = 0.2667.

LLM без RAG показала худшие результаты: Token F1 около 0.056-0.062, hallucination-like rate 0.80-0.90. Это подтверждает, что без исходного контекста модель часто даёт неподтверждённые ответы.

TF-IDF baseline оказался лучше LLM без RAG по F1, но хуже RAG-подходов. Лучший TF-IDF baseline достиг F1 = 0.2346 при top_k=3. При этом retrieved_contains_answer_rate = 0.88 показывает, что правильный ответ часто присутствовал в найденном контексте, но baseline не умел извлекать короткий точный ответ.

E5 retrieval дал самый высокий retrieved_contains_answer_rate = 0.9667, однако итоговый F1 = 0.4127 оказался ниже лучшего TF-IDF RAG. Это показывает, что сильный retrieval является необходимым, но не единственным условием хорошего QA.

7. Расширенные эксперименты

7.1. Популярность информации

Таблица 4 - Влияние популярности информации

Тип факта	Подход	n	EM	F1	Hall.	Refusal
context_specific	LLM + RAG	4	1.00	1.0000	0.00	0.00
context_specific	LLM no RAG	4	0.00	0.0000	0.25	0.75
popular	LLM + RAG	4	0.75	0.8611	0.00	0.00
popular	LLM no RAG	4	0.00	0.1000	0.50	0.25

На popular-фактах LLM + RAG получил $F1 = 0.8611$, а LLM без RAG - только 0.1000. На context-specific фактах RAG получил $F1 = 1.0000$, а LLM без RAG - 0.0000. Следовательно, наличие контекста оказалось важнее предположения о том, что факт является популярным.

7.2. Влияние русского и английского языка

Таблица 5 - Сравнение русского и английского QA

Язык	Подход	n	EM	F1	Hall.	Refusal
en	LLM + RAG	20	0.25	0.3496	0.30	0.25
en	LLM no RAG	20	0.00	0.0171	0.45	0.50
ru	LLM + RAG	20	0.05	0.4339	0.35	0.00
ru	LLM no RAG	20	0.00	0.0541	0.85	0.15

RAG улучшил качество на обоих языках. На английском $F1$ вырос с 0.0171 до 0.3496, а на русском - с 0.0541 до 0.4339. При этом LLM без RAG особенно плохо работала на русском QA: hallucination-like rate = 0.85.

7.3. Размер модели

Таблица 6 - Влияние размера модели

Модель	Подход	n	EM	F1	Hall.	Refusal
Qwen2.5-0.5B-Instruct	LLM + RAG	10	0.10	0.4644	0.20	0.20
Qwen2.5-0.5B-Instruct	LLM no RAG	10	0.00	0.0474	1.00	0.00
Qwen2.5-1.5B-Instruct	LLM + RAG	10	0.00	0.3041	0.20	0.20
Qwen2.5-1.5B-Instruct	LLM no RAG	10	0.00	0.0000	0.00	1.00




Рисунок 3 - Token F1 в расширенных экспериментах

Сравнение Qwen2.5-0.5B и Qwen2.5-1.5B не показало автоматического преимущества более крупной модели. На маленькой подвыборке Qwen 0.5B + RAG получил $F1 = 0.4644$, а Qwen 1.5B + RAG - 0.3041 . Без RAG обе модели работали слабо: 0.5B чаще галлюцинировала, а 1.5B чаще отказывалась отвечать.

8. Анализ ошибок

Анализ ошибок показал несколько основных типов проблем.

- Ошибки retrieval: найденный top-k контекст иногда не содержит правильный ответ или содержит неполный фрагмент.
- Неточное извлечение ответа: правильный ответ есть в найденном контексте, но LLM выбирает слишком широкий или соседний фрагмент.
- Галлюцинации LLM без RAG: модель даёт уверенный ответ, который не следует из исходного текста.
- Проблема строгих метрик: EM и Token F1 штрафуют длинные ответы с лишними словами, даже если часть правильного ответа присутствует.

- Отказы strict prompt: строгий prompt снижает часть галлюцинаций, но может увеличивать refusal rate и не всегда повышает итоговый F1.

Показательный пример из ноутбука: на вопрос «Кто сочетает в себе образы своих сёнэн-предшественников?» правильный ответ - «Наруто Удзумаки». LLM без RAG ответила нерелевантно: «Сёнэн-предшественниками являются древние русские писатели». Это типичная галлюцинация без контекста. RAG-подход передаёт модели фрагмент, где упоминается Наруто, и тем самым снижает риск такого ответа.

9. Ограничения подходов

Таблица 8 - Ограничения использованных подходов

Подход	Ограничение
TF-IDF baseline	Зависит от совпадения слов, плохо переносит переформулировки, возвращает длинные предложения вместо короткого ответа.
LLM без RAG	Не видит исходный контекст, поэтому отвечает из памяти, угадывает, галлюцинирует или отказывается.
LLM + TF-IDF RAG	Сильно зависит от top-k и качества лексического поиска; если правильный ответ не найден, генерация не поможет.
LLM + E5 RAG	Требует больше ресурсов; высокий Recall@k не гарантирует лучший итоговый ответ из-за ошибок генерации.
Увеличение размера LLM	Большая модель требует больше GPU-памяти и времени, но сама по себе не гарантирует лучший результат без хорошего retrieval-контекста.
Strict prompt	Может снижать галлюцинации, но иногда повышает долю отказов и не всегда улучшает F1.

10. Итоговые выводы

В работе была построена QA-система и проведено сравнение нескольких подходов: TF-IDF baseline, LLM без RAG, LLM + TF-IDF RAG и LLM + E5 RAG. Основная гипотеза подтвердилась: RAG заметно повышает качество ответов и снижает уровень потенциальных галлюцинаций по сравнению с LLM без внешнего контекста.

Лучший основной результат получен для LLM + RAG с TF-IDF retrieval, chunk_size=300, top_k=3, prompt_type=plain, temperature=0.0: EM = 0.1667, Token F1 = 0.4628, hallucination-like rate = 0.2667. По сравнению с LLM без RAG Token F1 вырос примерно с 0.06 до 0.46, а hallucination-like rate снизился с 0.80-0.90 до 0.2667.

Лучший метод выигрывает за счёт объединения retrieval и генерации. Retrieval находит фрагмент, где с высокой вероятностью находится ответ, а LLM преобразует найденный текст в короткую естественную формулировку. Именно поэтому RAG работает лучше, чем чистый поиск, и надёжнее, чем LLM без контекста.

Расширенные эксперименты показали, что RAG помогает на популярных и контекстно-зависимых фактах, на русском и английском QA, а также остаётся более важным фактором качества, чем простое увеличение размера модели. При этом система не является идеальной: она зависит от качества retrieval, prompt, языка, размера подвыборки и строгости выбранных QA-метрик.

11. Список использованных источников

1. Hugging Face Datasets: SberQuAD - <https://huggingface.co/datasets/kuznetsoffandrey/sberquad>
2. Hugging Face Datasets: SQuAD - <https://huggingface.co/datasets/rajpurkar/squad>
3. Qwen/Qwen2.5-0.5B-Instruct - <https://huggingface.co/Qwen/Qwen2.5-0.5B-Instruct>
4. Qwen/Qwen2.5-1.5B-Instruct - <https://huggingface.co/Qwen/Qwen2.5-1.5B-Instruct>
5. intfloat/multilingual-e5-small - <https://huggingface.co/intfloat/multilingual-e5-small>
6. scikit-learn TF-IDF Vectorizer - https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html
7. Sentence Transformers - <https://www.sbert.net/>